

## CONTRIBUTEURS

ACT-3000 Théorie du risque

**aut.** Gabriel Crépeault-Cauchon

**src.** Étienne Marceau

# 1 Rappels d'intro 2

## 1.1 Mesures de risques

Voir les preuves de TVaR en annexe. Il est pratique de se rappeler des 3 formes de la TVaR.

**Value-at-risk**  $VaR_\kappa(X) = F_X^{-1}(\kappa)$ . De plus, pour  $\varphi$  une fonction strictement croissante, on a que

$$VaR_\kappa(\varphi(X)) = \varphi(VaR_\kappa(X))$$

## 2 Distribution multivariées

### 2.1 Classes de Fréchet

Soit  $F_1, \dots, F_n$  des fonction de répartition univariées et  $F_X = F_{X_1, \dots, X_n}$  la fonction de répartition du vecteur  $\mathbf{X}$ .

On définit la classe de Fréchet  $CF(F_1, \dots, F_n)$  par l'ensemble des fonctions de répartition  $F_X$  dont les marginales sont  $F_1, \dots, F_n$ .

#### 2.1.1 Bornes d'une classe de Fréchet

Si  $F_X \in CF(F_1, \dots, F_n)$ , alors

$$W(x_1, \dots, x_n) \leq F_X(x_1, \dots, x_n) \leq M(x_1, \dots, x_n)$$

où

$$W(x_1, \dots, x_n) = \max \left( \sum_{i=1}^n F_i(x_i) - (n-1); 0 \right) \quad (1)$$

et

$$M(x_1, \dots, x_n) = \min(F_1(x_1), \dots, F_n(x_n)) \quad (2)$$

**Preuve des bornes à savoir!**

### 2.2 Comonotonicité

Les composantes de  $\mathbf{X}$  sont dites comonotones si  $X_i = F_{X_i}(U)$ ,  $i = 1, \dots, n$  et  $U \sim U(0,1)$ .

#### 2.2.1 Algorithme

1. Simuler  $U^{(j)}$  de la v.a.  $U \sim U(0,1)$
2. Calculer  $X_i^{(j)} = F_{X_i}(U^{(j)})$ ,  $i = 1, \dots, n$

1. L'antimonotonicité est seulement définie pour  $n = 2$ .

#### variable comonotone et la borne supérieure de Fréchet

Le vecteur  $\mathbf{X}$  a des composantes comonotones ssi

$$F_{\mathbf{X}}(x_1, \dots, x_n) = M(x_1, \dots, x_n)$$

**Preuve à savoir**

#### Additivité des VaR et TVaR

On définit  $S = \sum_{i=1}^n X_i = \sum_{i=1}^n F_{X_i}(U) = \varphi(U)$ , où  $\varphi$  est une fonction croissante pour  $y \in (0,1)$ . Alors, on a

$$VaR_\kappa(S) = \sum_{i=1}^n VaR_\kappa(X_i)$$

$$TVaR_\kappa(S) = \sum_{i=1}^n TVaR_\kappa(X_i)$$

**Preuve à savoir**

### 2.3 Antimonotonicité

Un couple de v.a.  $\mathbf{X} = (X_1, X_2)$  dont les composantes sont définies par  $X_1 = F_{X_1}(U)$  et  $X_2 = F_{X_2}(1 - U)$  est antimonotone par définition.

#### 2.3.1 Algorithme

1. Simuler  $U^{(j)}$  de la v.a.  $U \sim U(0,1)$
2. Calculer  $X_1^{(j)} = F_{X_1}(U^{(j)})$  et  $X_2^{(j)} = F_{X_2}(1 - U^{(j)})$

#### variable antimonotone et la borne inférieure de Fréchet

Le vecteur  $\mathbf{X} = (X_1, X_2)$  a des composantes antimonotone ssi

$$F_{\mathbf{X}}(x_1, x_2) = W(x_1, x_2)$$

**Preuve à savoir**

### 2.4 Loi de Poisson bivariable Teicher

- › Couple de v.a.  $(M_1, M_2)$  dont les marginales sont  $Pois(\lambda_1)$   $Pois(\lambda_2)$
- › paramètre de dépendance  $\alpha_0$  avec  $0 \leq \alpha_0 \leq \min(\lambda_1, \lambda_2)$
- ›  $\alpha_1 = \lambda - \alpha_0$  et  $\alpha_2 = \lambda_2 - \alpha_0$

- › On définit les v.a.  $M_1$  et  $M_2$  telles que (avec  $K_i \sim \text{Pois}(\alpha_i)$ )  
 $M_1 = K_1 + K_0$  et  $M_2 = K_2 + K_0$   
 avec  $M_i \sim \text{Pois}(\lambda_i)$

### 2.4.1 Fonction de masse de probabilité (fmp)

$$f_{M_1, M_2}(m_1, m_2) = e^{-\lambda_1 - \lambda_2 + \alpha_0} \sum_{j=0}^{\min(m_1, m_2)} \frac{\alpha_0^j}{j!} \frac{(\lambda_1 - \alpha_0)^{m_1 - j}}{(m_1 - j)!} \frac{(\lambda_2 - \alpha_0)^{m_2 - j}}{(m_2 - j)!}$$

Preuve à savoir

### 2.4.2 Fonction génératrice des probabilités (fgp)

$$P_{M_1, M_2}(t_1, t_2) = e^{(\lambda_1 - \alpha_0)(t_1 - 1)} e^{(\lambda_2 - \alpha_0)(t_2 - 1)} e^{\alpha_0(t_1 t_2 - 1)}$$

Preuve à savoir

**Covariance de  $M_1$  et  $M_2$**   $\text{Cov}(M_1, M_2) = \text{Var}(K_0) = \alpha_0$  Preuve à savoir

### 2.4.3 Connaître la loi de $N = M_1 + M_2$

À terminer

## 2.5 Loi exponentielle bivariee EFGM

**fonction de répartition** La fonction de répartition est

$$F_{X_1, X_2}(x_1, x_2) = (1 - e^{-\beta_1 x_1})(1 - e^{-\beta_2 x_2}) + \theta(1 - e^{-\beta_1 x_1})(1 - e^{-\beta_2 x_2})e^{-\beta_1 x_1}e^{-\beta_2 x_2}$$

**fgm** Il faut savoir prouver que la fgm est

$$M_{X_1, X_2}(t_1, t_2) = (1 + \theta) \left( \frac{\beta_1}{\beta_1 - t_1} \right) \left( \frac{\beta_2}{\beta_2 - t_2} \right) - \theta \left( \frac{2\beta_1}{2\beta_1 - t_1} \right) \left( \frac{\beta_2}{\beta_2 - t_2} \right) - \theta \left( \frac{\beta_1}{\beta_1 - t_1} \right) \left( \frac{2\beta_2}{2\beta_2 - t_2} \right) + \theta \left( \frac{2\beta_1}{2\beta_1 - t_1} \right) \left( \frac{2\beta_2}{2\beta_2 - t_2} \right)$$

2. Étude d'impact quantitative No4 du BSIF, 2012.

**Coefficient de corrélation** Il faut savoir prouver que la coefficient de corrélation est

$$\rho_P(X_1, X_2) = \frac{\theta}{4}$$

**Fonction de densité** On peut obtenir la fonction de densité de la loi exponentielle bivariee en dérivant 2 fois

$$f_{X_1, X_2}(x_1, x_2) = \frac{\partial^2}{\partial x_1 \partial x_2} F_{X_1, X_2}(x_1, x_2)$$

## 3 Problématiques d'un rapport du BSIF

Un extrait d'un rapport du BSIF<sup>2</sup> présente **plusieurs incohérences**, notamment :

- › La corrélation est la formule ou la méthode utilisée dans le présent document pour mesurer l'association entre des variables ;
- › L'intervalle de confiance est de -1 à 1
- › Une corrélation de 1 (corrélation positive parfaite) sous-entend que l'augmentation d'une variable donnée équivaldra à la hausse d'une autre variable ;
- › Une corrélation de -1 (corrélation négative parfaite) sous-entend que l'augmentation d'une variable donnée se traduira par une baisse correspondante d'une autre variable
- › Une corrélation zéro sous-entend l'absence de relation, ou indépendance, entre deux variables.

## 4 Théorie des copules

## Définition d'une copule



Une copule  $C$  est la fonction de répartition d'un vecteur de v.a  $\mathbf{U} = (U_1, U_2)$  dont les composantes  $U_i \sim U(0, 1)$ ,  $i = 1, 2$ . Une copule satisfait les propriétés suivantes :

- (1)  $C(u_1, u_2)$  est non-décroissante sur  $(0, 1)^2$
- (2)  $C(u_1, u_2)$  est continue à droite sur  $(0, 1)^2$
- (3)  $\lim_{u_i \rightarrow 0} C(u_1, u_2) = 0$ ,  $i = 1, 2$
- (4)  $\lim_{u_{3-i} \rightarrow 1} C(u_1, u_2) = u_i$ ,  $i = 1, 2$
- (5) Inégalité du rectangle :  $\forall a_i \leq b_i$ ,  $i = 1, 2$ , on a  

$$C(b_1, b_2) - C(b_1, a_2) - C(a_1, b_2) + C(a_1, a_2) \geq 0.$$
 Cette égalité sera satisfaite si  $\frac{\partial^2}{\partial u_1 \partial u_2} C(u_1, u_2) \geq 0$ .

On peut généraliser ces définitions pour une copule multivariée.

## 4.1 Théorème de Sklar

## Théorème de Sklar



Soit  $F_X \in \mathcal{CF}(F_1, F_2)$  ayant les fonctions de répartition  $F_1$  et  $F_2$ . Il y a 2 volets au théorème :

**Volet # 1** Il existe une copule  $C$  telle que,  $\forall x \in \mathbb{R}^n$ ,  

$$F(x_1, \dots, x_n) = C(F_1(x_1), \dots, F_n(x_n))$$

**Volet # 2** Inversement, si  $C$  est une copule de  $F_1, \dots, F_n$  sont des fonctions de répartition, alors la fonction définie par  

$$F(x_1, \dots, x_n) = C(F_1(x_1), \dots, F_n(x_n))$$
 est une fonction de répartition multivariée avec les fonctions de répartition marginales  $F_1, \dots, F_n$ .

À prouver

## 4.2 Comment extraire une copule ?

Soit un vecteur de v.a. continues avec fonction de répartition  $F_X \in \mathcal{CF}(F_1, \dots, F_n)$ . Alors, la copule  $C$  associée à  $F_X$  est donnée par

$$C(u_1, \dots, u_n) = F_X(F_1^{-1}(u_1), \dots, F_n^{-1}(u_n)) \quad (3)$$

## 4.3 Bornes de Fréchet

Puisque  $C$  est une fonction de répartition, on a

$$W(u_1, \dots, u_n) \leq C(u_1, \dots, u_n) \leq M(u_1, \dots, u_n)$$

où  $W$  et  $M$  sont les bornes inférieures (voir Éq. 1) et supérieures (voir Éq. 2), respectivement .

## 4.4 Fonction de densité d'une copule

$$c(u_1, \dots, u_n) = \frac{\partial^2}{\partial u_1 \dots \partial u_n} C(u_1, \dots, u_n) \quad (4)$$

De plus, on a

$$\begin{aligned} f_X(x_1, \dots, x_n) &= \frac{\partial^2}{\partial u_1 \dots \partial u_n} F_X(x_1, \dots, x_n) \\ &= \frac{\partial^2}{\partial u_1 \dots \partial u_n} C(F_1(x_1), \dots, F_n(x_n)) \\ &= c(u_1, \dots, u_n) f_{X_1}(x_1) \dots f_{X_n}(x_n) \end{aligned}$$

## 4.5 Fonction de répartition conditionnelle d'une copule

$$C_{2|1}(u_2|u_1) = \frac{\partial}{\partial u_1} C(u_1, u_2) \quad (5)$$

Une relation similaire existe pour  $C_{1|2}$ . On peut obtenir, par exemple, la fonction de répartition conditionnelle  $F_{X_2|X_1=x_1}(x_2)$  avec

$$F_{X_2|X_1=x_1}(x_2) = C_{2|1}(F_{X_2}(x_2)|F_{X_1}(x_1))$$

## 4.6 Construction d'une copule archimédienne

Une copule archimédienne est construite à partir de 2 v.a  $Y_i|\Theta \sim \text{Exp}(\Theta)$ ,  $i = 1, 2$  (et  $\Theta$  qui suit une certaine distribution) peut être construite avec

$$C(u_1, u_2) = \bar{F}_Y(\bar{F}_{Y_1}^{-1}(u_1), \bar{F}_{Y_2}^{-1}(u_2)) \quad (6)$$

où l'on déduit que

$$F_{Y_i}(x_i) = E[F_{Y|\Theta}(x_i|\theta)] = E[e^{-\Theta x}] = \mathcal{L}_\Theta(x)$$

Plusieurs copules possibles :

**Clayton**  $\Theta \sim \Gamma(\frac{1}{\alpha}, 1)$

**AMH**  $\Theta \sim \text{BinNég}$

**Frank**  $\Theta \sim \text{Logarithmique}(\gamma = 1 - e^{-\alpha})$

## 4.7 Méthode des rectangles

On peut approximer  $F_S(s)$  avec la méthode des rectangles<sup>3</sup>

### 4.7.1 Méthode *lower*

On additionne les masses de probabilité associées aux  $2^m - 1$  rectangles se trouvant en-dessous de la diagonale  $x_1 + x_2 = s$ .

$$A_S^{(l,m)}(s) = \sum_{i=1}^{2^m-1} \left[ F_{X_1, X_2} \left( \frac{i}{2^m} s, \frac{2^m - i}{2^m} s \right) - F_{X_1, X_2} \left( \frac{i-1}{2^m} s, \frac{2^m - i}{2^m} s \right) \right] \quad (7)$$

### 4.7.2 Méthode *upper*

On additionne les masses de probabilité associées aux  $2^m$  rectangles se trouvant au-dessus de la diagonale  $x_1 + x_2 = s$

$$A_S^{(u,m)}(s) = \sum_{i=1}^{2^m} \left[ F_{X_1, X_2} \left( \frac{i}{2^m} s, \frac{2^m + 1 - i}{2^m} s \right) - F_{X_1, X_2} \left( \frac{i-1}{2^m} s, \frac{2^m + 1 - i}{2^m} s \right) \right] \quad (8)$$

On a que

$$A_S^{(l,m)}(s) \leq A_S^{(l,m+k)}(s) \leq F_S(s) \leq A_S^{(u,m+k)}(s) \leq A_S^{(u,m)}(s).$$

3. Plutôt que d'apprendre les formules ci-dessous, il est mieux de se dessiner les rectangles par rapport à la diagonale puis déduire les  $F_{X_1, X_2}$  à additionner et soustraire.

## 5 Annexe

### 5.1 Les 3 formes explicites de la $TVaR$

Pour la  $TVaR$ , il y a 3 preuves à bien connaître :

$$TVaR_\kappa(X) = \frac{1}{1-\kappa} \pi_X(VaR_\kappa(X)) + VaR_\kappa(X)$$

Démonstration.

$$\begin{aligned} TVaR_\kappa(X) &= \frac{1}{1-\kappa} \int_\kappa^1 VaR_u(X) du \\ &= \frac{1}{1-\kappa} \int_\kappa^1 (VaR_u(X) - VaR_\kappa(X) + VaR_\kappa(X)) du \\ &= \frac{1}{1-\kappa} \int_\kappa^1 \underbrace{(VaR_u(X) - VaR_\kappa(X))}_{\text{fonction quantile}} du + \underbrace{\int_\kappa^1 VaR_\kappa(X) du}_{\text{intégration d'une constante}} \\ &= \frac{1}{1-\kappa} \int_\kappa^1 (F_X^{-1}(u) - VaR_\kappa(X)) \underbrace{f_U(u)}_{U \sim \text{Unif}(0,1)} du \\ &\quad + \frac{1}{1-\kappa} VaR_\kappa(X) (1-\kappa) \\ &= \frac{1}{1-\kappa} E[\max(\underbrace{F_X^{-1}(U)}_{F_X^{-1} \sim X} - VaR_\kappa(X); 0)] + VaR_\kappa(X) \\ &= \frac{1}{1-\kappa} E[\max(X - VaR_\kappa(X); 0)] + VaR_\kappa(X) \\ &= \frac{1}{1-\kappa} \pi_X(VaR_\kappa(X)) + VaR_\kappa(X) \end{aligned}$$

à partir de la preuve ci-dessus, on peut démontrer celle-ci :

$$TVaR_\kappa(X) = \frac{E[X \times 1_{\{X > VaR_\kappa(X)\}}] + VaR_\kappa(X)(F_X(VaR_\kappa(X)) - \kappa)}{1-\kappa}$$

Démonstration.

$$\begin{aligned} TVaR_\kappa(X) &= \frac{1}{1-\kappa} \pi_X(VaR_\kappa(X)) + VaR_\kappa(X) \\ &= \frac{1}{1-\kappa} E[\max(X - VaR_\kappa(X); 0)] + VaR_\kappa(X) \\ &= \frac{1}{1-\kappa} E[(X - VaR_\kappa(X)) \times 1_{\{X > VaR_\kappa(X)\}}] + VaR_\kappa(X) \\ &= \frac{1}{1-\kappa} E[X \times 1_{\{X > VaR_\kappa(X)\}}] - \frac{1}{1-\kappa} E[VaR_\kappa(X) \times \underbrace{1_{\{X > VaR_\kappa(X)\}}}_{=S_X(VaR_\kappa(X))}] \\ &\quad + VaR_\kappa(X) \\ &= \frac{1}{1-\kappa} E[X \times 1_{\{X > VaR_\kappa(X)\}}] - \frac{1}{1-\kappa} VaR_\kappa(X)(1 - F_X(VaR_\kappa(X))) \\ &\quad + \frac{1-\kappa}{1-\kappa} VaR_\kappa(X) \\ &= \frac{E[X \times 1_{\{X > VaR_\kappa(X)\}}] + VaR_\kappa(X)(-1 + F_X(VaR_\kappa(X)) + 1 - \kappa)}{1-\kappa} \\ &= \frac{E[X \times 1_{\{X > VaR_\kappa(X)\}}] + VaR_\kappa(X)(F_X(VaR_\kappa(X)) - \kappa)}{1-\kappa} \end{aligned}$$

□

Une dernière preuve fortement utilisée pour la  $TVaR$ , qui découle directement de la dernière :

$$TVaR_\kappa(X) = \frac{E[X \times 1_{\{X > VaR_\kappa(X)\}}]}{1-\kappa}$$

Démonstration. Étant donné que cette formule ne fonctionne seulement que pour une v.a. continue, elle est très facile à prouver :

si  $X$  est continue,  $\forall x, F_X(VaR_\kappa(X)) = \kappa$

Alors, on peut enlever la partie de droite de l'équation.

□

□