

### 3 Estimation non-paramétrique

#### Moments à savoir

$$\begin{aligned}\mu'_k &= E[X^k] \\ \mu_k &= E[(X - \mu)^k] \\ CV &= \frac{\sigma}{\mu} \\ \gamma &= \frac{\mu_3}{\sigma^3} \\ \kappa &= \frac{\mu_4}{\sigma^4}\end{aligned}$$

#### 3 critères pour évaluer les queues de distributions

1. La loi avec le moins de moments a la queue la plus lourde.
2. Première à diverger du quotient des distributions a la queue la plus lourde.

$$\lim_{x \rightarrow \infty} \frac{f_{X_1}(x)}{f_{X_2}(x)}$$

3. Si la fonction hasard  $h(x) = \frac{f_X(x)}{S_X(x)}$  est croissante alors la queue est fine, sinon elle est lourde.

$$\begin{aligned}h'_X(x) &< 0 && \text{queue lourde} \\ h'_X(x) &> 0 && \text{queue fine}\end{aligned}$$

#### Quantités des distributions à connaître

$Y^P$  : **Excess loss**, alias **left truncated** and **shifted** variable.  
On interprète comme le *montant de perte en excès d'un déductible d* sachant que la perte est au delà de ce montant.

$Y^L$  : **Left censored** and **shifted** variable.  
Elle est défini comme étant 0 pour toutes les pertes inférieures à d, alors que l'excès-moyen n'est simplement pas défini dans ces cas.  
Donc, celle-ci a une masse à 0.

$Y$  : **Limited loss**, alias **right censored** variable.

**shifted** : d est soustrait des valeurs restantes.  
On peut visualiser le déplacement de la courbe de densité à la gauche.

**left truncated** : Toutes valeurs inférieures à d ne sont pas observées.

**left censored** : Toutes valeurs inférieures à d sont égale à 0.

**right censored** : Toutes valeurs supérieures à u sont égale à u.

*Pour exemple*, lorsqu'il y a une limite sur une police d'assurance les valeurs au-delà ne sont pas typiquement inscrites à leur vrai montant, mais plutôt comme la limite u.

#### Moments

$$E[Y^P] = E[X - d | X \geq d] = \frac{\int_d^\infty S_X(x) dx}{S_X(d)} = e_X(d)$$

$$E[Y^L] = E[(X - d)_+] = \int_d^\infty (x - d) f_X(x) dx$$

$$E[Y] = E[X \wedge d] = \int_0^d f_X(x) dx \Leftrightarrow \int_0^d S_X(x) dx$$

### 8 Fréquence et sévérité avec modifications aux contrats

#### Déductible ordinaire

L'assureur paye tout montant en excédent du montant d.

$$Y^L = (X - d)_+ = \begin{cases} 0 & , X \leq d \\ X - d & , X > d \end{cases}$$

$$Y^P = (X - d)_+ = \begin{cases} \text{Non-défini} & , X \leq d \\ X - d & , X > d \end{cases}$$

#### Déductible franchise

L'assureur paye l'entièreté des coûts pour toute perte qui surpasse le montant d.

*Pour éviter les petites réclamations*

$$Y^L = (X - d)_+ = \begin{cases} 0 & , X \leq d \\ X & , X > d \end{cases}$$

$$Y^P = (X - d)_+ = \begin{cases} \text{Non-défini} & , X \leq d \\ X & , X > d \end{cases}$$

#### Moments

$$E[Y_{(O|F)}^{(L|P)}] = \frac{E[X] - E[X \wedge d] + d S_X(d)}{S_X(d)}$$

Où (L|P) et (O|F) est à être interprété en REGEX.  
C'est soit per loss (L) ou **per payment (P)**  
C'est soit un déductible ordinaire (O) ou **avec franchise (F)**.  
De plus, on note que :

$$E[Y_{(O)}^{(P)}] = e_X(d)$$

$$E[Y_{(O)}^{(L)}] = \pi_X(d)$$

#### Fonctions

$$f_{Y_{(O)}^{(L|P)}} = \frac{f_X(y + d)}{S_X(d)}$$

$$S_{Y_{(O)}^{(L|P)}} = \frac{S_X(y + d)}{S_X(d)}$$

$$F_{Y_{(O)}^{(L|P)}} = \frac{F_X(y + d) - F_X(d)}{S_X(d)}$$

$$h_{Y_{(O)}^{(Y|P)}} = h_X(y + d)$$

## LER et inflation du déductible ordinaire

Le LER nous donne le pourcentage de perte qu'on ne paie pas grâce au déductible

$$\begin{aligned} LER &= \frac{E[X] - E[(X - u)_+]}{E[X]} \\ &= \frac{E[X \wedge u]}{E[X]} \end{aligned}$$

Soit  $X^I = (1 + r)X$

$$E[X^I \wedge u] = (1 + r)E[X \wedge \frac{u}{1 + r}]$$

$$f_{X^I}(x) = \frac{f_X\left(\frac{y}{1 + r}\right)}{1 + r}$$

$$F_{X^I}(x) = F_X\left(\frac{y}{1 + r}\right)$$

## Limite de police

L'assureur paye un maximum de  $u$

$$Y = (X \wedge u) = \begin{cases} X, & X < u \\ u, & X \geq u \end{cases}$$

$$f_Y(y) = \begin{cases} f_X(y), & y < u \\ S_X(u), & y = u \end{cases}$$

$$F_Y(y) = \begin{cases} F_X(y), & y \leq u \\ 1, & y > u \end{cases}$$

## Coassurance

L'assureur paye une fraction,  $\alpha$ , de la perte.

Si la coassurance est la seule modification, alors nous obtenons  $Y = \alpha X$ .

L'impact sur les fonctions est le même qu'avec de l'inflation.

## Formule récapitulative

Lorsque les 4 items sont présent (déductible ordinaire, limite, inflation et coassurance).

$$Y^L = \begin{cases} 0 & , x < \frac{d}{1+r} \\ \alpha((1+r)x - d) & , \frac{d}{1+r} \leq x < \frac{u}{1+r} \\ \alpha(u - d) & , x \geq \frac{u}{1+r} \end{cases}$$

$$Y^P = \begin{cases} \text{Non-défini} & , x < \frac{d}{1+r} \\ \alpha((1+r)x - d) & , \frac{d}{1+r} \leq x < \frac{u}{1+r} \\ \alpha(u - d) & , x \geq \frac{u}{1+r} \end{cases}$$

$$E[Y^L] = \alpha(1 + r) \left( E\left[X \wedge \frac{u}{1 + r}\right] - E\left[X \wedge \frac{d}{1 + r}\right] \right)$$

$$E[Y^P] = \frac{E[Y^L]}{S_X\left(\frac{d}{1+r}\right)}$$

## 14 Estimation non-paramétrique des fonctions de répartition et de survie

### Distribution empirique avec données complètes

$$\text{I.C. au niveau } 1 - \alpha \text{ de } F(x) \in \left[ F_n(x) \pm z_{1-\frac{\alpha}{2}} \sqrt{\widehat{V}(F_n(x))} \right]$$

$y_j$ : la  $j$ -ème des  $k$  valeurs unique de l'échantillon de  $n$  ( $k \leq n$ ).

$$y_1 < y_2 < \dots < y_k$$

$s_j$ : Nombre de fois que l'observation  $y_j$  est observé dans l'échantillon.

$$\sum_{j=1}^k s_j = n$$

$r_j$ : Nombre d'observations  $\geq y_j$ .

$$\sum_{i=j}^k s_i = r_j$$

$$F_n(x) = \frac{1}{n} \sum_{j=1}^n I_{\{x_j \leq x\}}$$

$$f_n(x) = \frac{1}{n} \sum_{j=1}^n I_{\{x_j = x\}}$$

$$nF_n(x) \sim \text{bin}(n, F(x))$$

$$E[F_n(x)] = \frac{nF_n(x)}{n} = F_n(x)$$

$$\widehat{Var}[F_n(x)] = \frac{nF_n(x)(1 - F_n(x))}{n^2} = \frac{F_n(x)(1 - F_n(x))}{n}$$

$$\widehat{Var}[S_n(x)] = \frac{S_n(x)(1 - S_n(x))}{n}$$

$$F_n(x) = \begin{cases} 0, & x < y_1 \\ 1 - \frac{r_j}{n}, & y_{j-1} \leq x < y_j, j = 2, \dots, k \\ 1, & x > y_k \end{cases}$$

### Distribution empirique avec données groupées

#### Fonction OGIVE

- Dans certains contextes, on a  $n$  données qui sont groupées en intervalles et la fonction OGIVE permet d'interpoler entre 2 points  $c_{j-1}$  et  $c_j$ .
- On définit  $n_j$  comme étant le nombre d'observations entre  $c_{j-1}$  et  $c_j$ .
- Soit  $x$  tel que

$$c_{j-1} \leq x \leq c_j$$

$$F_n(c_{j-1}) \leq F_n(x) \leq F_n(c_j)$$

Alors

$$\begin{aligned} F_n^{\text{OGIVE}}(x) &= \alpha F_n(c_{j-1}) + (1 - \alpha) F_n(c_j) \\ &= \frac{c_j - x}{c_j - c_{j-1}} F_n(c_{j-1}) + \frac{x - c_{j-1}}{c_j - c_{j-1}} F_n(c_j) \end{aligned}$$

$$\text{où } F_n(c_j) = \frac{\sum_{i=1}^j n_i}{n}$$

$$f_n(x) = \frac{F_n(c_j) - F_n(c_{j-1})}{c_j - c_{j-1}} \Leftrightarrow \frac{n_j}{n(c_j - c_{j-1})}$$

## Estimations empirique avec données censurées à droite

On représente les données censurées avec :

$b_i$  : Nombre d'observations censurées à la droite dans l'intervalle  $[y_i, y_{i+1}) \forall i = 1, 2, \dots, k-1$

De plus, on interprète les valeurs définies plus haut.

$s_i$  : Nombre de décès au temps  $i$ .

$r_i$  : Le nombre à *risque* à l'observation  $y_i$ .

$$r_i = \begin{cases} n, & i = 1 \\ r_{i-1} - s_{i-1} - b_{i-1}, & i = 2, 3, \dots, k+1 \end{cases}$$

Par la suite, on peut interpréter la fonction de survie comme une probabilité conditionnelle puisque  $S(t_0) = 1$ .

$$S(t) = \frac{S(t_1)}{S(t_0)} \times \frac{S(t_2)}{S(t_1)} \times \dots \times \frac{S(t)}{S(t-1)} \\ \Leftrightarrow p_1 \times p_2 \times \dots \times p_t = \prod_{j \leq t} p_j$$

où  $p_t = P(T > t | T > t-1)$

et  $q_t = P(T < t | T > t-1)$

On peut donc estimer  $p_j$  par :

$$\hat{p}_j = 1 - \hat{q}_j = 1 - \hat{\lambda}_j = 1 - \frac{S_j}{r_j}$$

où  $S_j \sim \text{Bin}(r_j, q_j)$

Pour obtenir l'estimateur **Kaplan-Meier** :

$$S_m(t) = \prod_{j \leq t} \left( 1 - \frac{S_j}{r_j} \right)$$

On utilise la **méthode Delta** pour trouver la variance :

$$V(g(\hat{\theta})) = (g'(\hat{\theta}_0))^2 V(\hat{\theta})$$

Pour ensuite obtenir :

$$V(S_n(t)) = (S_n(t))^2 \sum_{j \leq t} \frac{q_j}{r_j p_j}$$

On peut donc estimer cette variance avec la (**Formule de Greenwood**) :

$$\hat{V}[S_n(t)] = (S_n(t))^2 \sum_{j \leq t} \frac{S_j}{r_i(r_i - S_i)}$$

On reprends la même notation pour trouver l'estimateur **Nelson-Aalen** :

$$\hat{H}(t) = \sum_{j \leq t} \left( \frac{S_j}{r_j} \right)$$

On peut ensuite déduire la fonction de survie empirique :

$$S_m(t) = e^{\hat{H}(t)}$$

La variance de la **cumulative hazard rate function** est représentée comme suit :

$$V(\hat{H}(t)) = \sum_{j \leq t} V\left(\frac{S_j}{r_j}\right) = \frac{q_j p_j}{r_j}$$

Ce qu'on peut ensuite estimer avec la **formule de Klein** :

$$\hat{V}(\hat{H}(t)) = \sum_{j \leq t} \frac{\hat{q}_j \hat{p}_j}{r_j} = \frac{S_j(r_j - S_j)}{r_j^3}$$

## 15 Fonction génératrice cumulée

Soit la fonction génératrice des moments  $M_X(t)$ , telle que

$$M_X(t) = E[e^{tX}]$$

Alors, la fonction génératrice cumulée  $K_X(t)$  est définie comme

$$K(t) = \frac{\partial}{\partial t} \ln M_X(t)$$

De plus, la fonction génératrice cumulée a les propriétés suivantes :

$$K'(t) \Big|_{t=0} = E[X]$$

$$K''(t) \Big|_{t=0} = \text{Var}(X)$$

## 16 Frequentist estimation

### Méthode des moments

On résoud  $p$  équations à  $p$  inconnus, telles que

$$\hat{\mu}'_k = \mu'_k$$

### Méthode des percentiles

On résoud  $p$  équations à  $p$  inconnus (paramètres) telles que

$$F_n(\hat{\pi}_{g_i}) = g_i \quad i = 1, \dots, p$$

où  $\hat{\pi}_{g_i}$  est le  $g_i^e$  quantile de la fonction empirique.

### Smoothed empirical estimate

Parfois, le quantile recherché tombe entre 2 marches de la fonction empirique. On utilise l'approximation linéaire suivante avec les statistiques d'ordre  $X_{(j)}$  :

$$\hat{\pi}_g = (1-h)X_{(j)} + hX_{(j+1)}$$

avec  $j = \lfloor (n+1)g \rfloor$  et  $h = (n+1)g - j$ .

### Méthode du maximum de vraisemblance (MLE)

#### Données complètes

On définit la fonction de vraisemblance  $L(\theta)$  telle que

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

Et la fonction de log-vraisemblance  $\ell(\theta)$

$$\ell(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$$

L'estimateur du maximum de vraisemblance  $\theta$  maximiser  $L(\theta)$  ou  $\ell(\theta)$ , i.e.

$$\frac{\partial}{\partial \theta} \ell(\theta) \Big|_{\theta=\hat{\theta}_{MLE}} = 0$$

## Données groupées

Si les données sont groupées, alors on utilise une forme plus générale de la fonction de vraisemblance :

$$L(\theta) = \prod_{j=1}^k \left( F_X(c_j; \theta) - F_X(c_{j-1}; \theta) \right)^{n_j}$$

où  $F_X$  est la fonction de répartition théorique de la distribution qu'on suppose la distribution de notre estimateur *MLE*. Si les données sont censurés à la classe  $c_{j-1}$ , alors on utilise  $(1 - F_X(c_{j-1}; \theta))$ .

## Variance des estimateurs et intervalle de confiance

### Estimation de la variance de $\hat{\theta}$

L'information de Fisher  $I(\theta)$  est définie par

$$I(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} \ell(\theta) \right] = E \left[ \left( \frac{\partial}{\partial \theta} \ell(\theta) \right)^2 \right]$$

Si l'information n'est pas connue, on peut l'estimer avec l'information observée :

$$\hat{I}(\hat{\theta}) = \sum_{i=1}^n \left( \frac{\partial}{\partial \theta} \ln f(x_i; \theta) \Big|_{\theta=\hat{\theta}} \right)^2 = - \sum_{i=1}^n \frac{\partial^2}{\partial \theta^2} \ln f(x_i; \theta) \Big|_{\theta=\hat{\theta}}$$

Ainsi, on peut calculer la variance de l'estimateur  $\hat{\theta}_{MLE}$  telle que

$$\text{Var}(\hat{\theta}) = I(\theta)^{-1}$$

### Intervalle de confiance pour $\hat{\theta}$

Lorsque  $n \rightarrow \infty$ ,  $\hat{\theta} \sim N(\theta, \text{Var}(\hat{\theta}))$ . Alors, on peut trouver un IC pour l'estimateur au seuil  $1 - \alpha$  :

$$\theta \in \left[ \hat{\theta} \pm z_{\alpha/2} \sqrt{\text{Var}(\hat{\theta})} \right]$$

## Méthode delta pour estimer la variance d'une transformation de $\hat{\theta}$

Lorsqu'on veut calculer la variance d'une autre quantité que le paramètre  $\hat{\theta}$  lui-même, on peut utiliser la méthode Delta :

$$\text{Var}(h(\hat{\theta})) = \left( \frac{\partial}{\partial \theta} h(\theta) \right)^2 \text{Var}(\hat{\theta})$$

Dans un contexte multivarié, où  $\hat{\theta}$  est un vecteur d'estimateurs, alors on a

$$\text{Var}(h(\hat{\theta})) = \mathbf{h}^\top I(\theta)^{-1} \mathbf{h}$$

où  $\mathbf{h}$  est le vecteur des dérivées partielles de  $h(\theta)$  :

$$\mathbf{h} = \begin{bmatrix} \frac{\partial}{\partial \theta_1} h(\theta) \\ \frac{\partial}{\partial \theta_2} h(\theta) \\ \dots \\ \frac{\partial}{\partial \theta_k} h(\theta) \end{bmatrix}$$

## Test du rapport de vraisemblance (LRT)

On veut tester si le modèle réduit avec  $\theta_0$ , qui est une bonne simplification de  $\theta_1$ , le modèle complet. Alors, on teste si la différence dans les log-vraisemblance est significative :

$$T = 2(\ell(\theta) - \ell(\theta_0)) \sim \chi_{dl_1 - dl_0, 1-\alpha}^2$$


où  $dl_1$  est le nombre de paramètres non-fixés du modèle complet et  $dl_0$  le nombre de paramètres non-fixés du modèle réduit. **On va rejeter  $H_0$  si  $T > \chi_{dl_1 - dl_0, 1-\alpha}^2$  (test unilatéral)**, en concluant que le modèle réduit n'est pas une bonne simplification du modèle de l'hypothèse alternative.

## Construction d'un intervalle de confiance par inversion du LRT

Si  $\theta_0$  est un paramètre adéquat pour le modèle réduit, alors la statistique  $T$  du LRT ne dépassera pas le quantile théorique  $\chi_{dl_1 - dl_0, 1-\alpha}^2$ . Alors, on veut trouver  $\hat{\theta}_0$  tel que

$$2(\ell(\theta) - \ell(\theta_0)) \leq \chi_{dl_1 - dl_0, 1-\alpha}^2$$

On trouvera une équation du genre  $g(\theta) \leq 0$ , où  $g$  sera une fonction avec deux racines définies, qui correspondent aux bornes de l'intervalle de confiance pour les valeurs de  $\hat{\theta}_0$  :



## 17 Sélection de modèles

### Chi-Square Goodness-of-fit

On veut valider l'adéquation du modèle qu'on propose avec ce test. On calcule la quantité  $X^2$  :

$$X^2 = \frac{\sum_{j=1}^k (E_j - O_j)^2}{E_j}$$

où  $E_j = n\hat{p}_i$  est le nombre de valeurs qu'on s'attend à avoir dans la  $i^e$  classe et  $O_j = np_{ni}$  le nombre d'observations dans la  $i^e$  classe. On peut prouver que

$$X^2 \sim \chi_{k-p-1}^2$$

On peut aussi faire le test LRT pour valider l'adéquation aussi.

## Critères de sélection

Pour choisir entre plusieurs modèles, on peut, entre autres, se baser sur les critères suivants :

1. la plus **faible valeur** pour le test **Kolmogorov-Smirnov**;
2. la plus **faible valeur** pour le test **Anderson-Darling**;
3. la plus **faible valeur** pour le test **Goodness-of-fit**;
4. la plus **haute valeur** pour la **p-value** du test **Goodness-of-fit**;
5. la plus **haute valeur** pour la **fonction de vraisemblance à son maximum**.

## 18 Estimation bayésienne

**Distribution *a priori***

Soit un paramètre  $\theta$  d'une distribution quelconque. Afin de réaliser une estimation Bayésienne, on connaît *a priori* la distribution que prend le paramètre  $\theta$ , qu'on dénote par  $\pi(\theta)$ .

Alors, notre distribution des pertes est conditionnée par rapport à la valeur que  $\theta$  prend (i.e.  $f_{X|\Theta}$ ).

**Distribution *a posteriori***

La distribution *a posteriori* nous permet de savoir avec quelle probabilité non-nulle notre paramètre  $\theta$  peut prendre une certaine valeur, sachant qu'on a observé certains  $x$ , qu'on dénote comme  $\pi_{\Theta|X}(\theta|x)$  :

$$\pi_{\Theta|X}(\theta|x) = \frac{f_{\Theta,X}(\theta, x)}{f_X(x)} = \frac{f_{X|\Theta}(x|\theta)\pi(\theta)}{\int f_{X|\Theta}(x|\theta)\pi(\theta)d\theta} \quad (1)$$

L'idée est de remplacer les différentes distributions dans l'Équation 1, et en déduire une distribution avec une paramétrisation différente<sup>a</sup>.

<sup>a</sup>. Souvent, la distribution *a posteriori* aura la même distribution que celle *a priori*, mais avec des paramètres différents.

**Rappels d'algèbre linéaire****Matrice transposée**

la matrice transposée est définie par  $A^\top$ , telle que

$$A^\top = \begin{bmatrix} a & -c \\ -b & d \end{bmatrix}$$

**Déterminant d'une matrice**

On peut calculer le déterminant  $\det(A)$  de la matrice  $A$  tel que

$$\det(A) = \begin{vmatrix} a & b \\ c & d \end{vmatrix} = ad - bc$$

**Inverse d'une matrice**

L'équivalent de l'opération  $\frac{1}{A}$  en algèbre linéaire est de calculer la matrice inverse de  $A^{-1}$ , telle que

$$A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} a & -c \\ -b & d \end{bmatrix}$$

où on multiplie par la matrice adjointe de  $A$ . Il faut normalement calculer les cofacteurs, mais le cas à 2 dimensions est un cas simplifié.

**L'estimateur Bayésien** L'estimateur Bayésien est défini comme l'espérance du paramètre  $\theta$ , sachant la distribution de  $X$ . En d'autres mots, on veut l'espérance de la distribution *a posteriori* :

$$\hat{\theta}_{BAYES} = E[\Theta|X] \quad (2)$$

**19 Rappel de probabilité****Certaines lois à savoir**

Loi	$\Pr(X = x)$ ou $f_X(x)$	$E[X]$	$Var(X)$	$M_X(t)$
$Bin(n, p)$	$\binom{n}{x} p^x (1-p)^{n-x}$	$np$	$np(1-p)$	$((1-p) + pt)^n$
$Pois(\lambda)$	$\frac{e^{-\lambda} \lambda^x}{x!}$	$\lambda$	$\lambda$	$e^{\lambda(t-1)}$
$Gamma(\alpha, \lambda)$	$\frac{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)}$	$\frac{\alpha}{\lambda}$	$\frac{\alpha}{\lambda^2}$	$\left(\frac{\lambda}{\lambda-t}\right)^\alpha$
$Normale(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$	$\mu$	$\sigma^2$	$e^{\mu t + \frac{\sigma^2 t^2}{2}}$